



دانشکده مهندسی کامپیوتر

بهبود کیفیت تصاویر به کمک تکنیک‌های هوش مصنوعی

پروژه کارشناسی مهندسی کامپیوتر گرایش هوش مصنوعی و رباتیک

علی عطاریان

استاد راهنما

دکتر آرش عبدی هجراندوست

اسفند ۱۴۰۴



تأییدیه‌ی هیأت داوران جلسه‌ی دفاع از پروژه

نام دانشکده: دانشکده مهندسی کامپیوتر

نام دانشجو: علی عطاریان

عنوان پروژه: بهبود کیفیت تصاویر به کمک تکنیک‌های هوش مصنوعی

تاریخ دفاع: اسفند ۱۴۰۴

رشته: مهندسی کامپیوتر

گرایش: هوش مصنوعی و رباتیکز

ردیف	سمت	نام و نام خانوادگی	مرتبه دانشگاهی	دانشگاه یا مؤسسه	امضاء
۱	استاد راهنما	دکتر آرش عبدی هجراندوست	استادیار	علم و صنعت ایران	
۲	استاد داور	دکتر محمدرضا محمدی	استادیار	علم و صنعت ایران	

تأییدیه‌ی صحت و اصالت نتایج

باسمه تعالی

اینجانب علی عطاریان به شماره دانشجویی ۹۹۵۲۱۴۵۱ دانشجوی رشته مهندسی کامپیوتر مقطع تحصیلی کارشناسی تأیید می‌نمایم که کلیه‌ی نتایج این پروژه حاصل کار اینجانب و بدون هرگونه دخل و تصرف است و موارد نسخه‌برداری شده از آثار دیگران را با ذکر کامل مشخصات منبع ذکر کرده‌ام. در صورت اثبات خلاف مندرجات فوق، به تشخیص دانشگاه مطابق با ضوابط و مقررات حاکم (قانون حمایت از حقوق مؤلفان و مصنفان و قانون ترجمه و تکثیر کتب و نشریات و آثار صوتی، ضوابط و مقررات آموزشی، پژوهشی و انضباطی ...) با اینجانب رفتار خواهد شد و حق هرگونه اعتراض در خصوص احقاق حقوق مکتسب و تشخیص و تعیین تخلف و مجازات را از خویش سلب می‌نمایم. در ضمن، مسئولیت هرگونه پاسخگویی به اشخاص اعم از حقیقی و حقوقی و مراجع ذیصلاح (اعم از اداری و قضایی) به عهده‌ی اینجانب خواهد بود و دانشگاه هیچ‌گونه مسئولیتی در این خصوص نخواهد داشت.

نام و نام خانوادگی: علی عطاریان

تاریخ و امضا:

مجوز بهره‌برداری از پایان‌نامه

بهره‌برداری از این پایان‌نامه در چهارچوب مقررات کتابخانه و با توجه به محدودیتی که توسط استاد راهنما به شرح زیر تعیین می‌شود، بلامانع است:

- ☐ بهره‌برداری از این پایان‌نامه برای همگان بلامانع است.
- ☐ بهره‌برداری از این پایان‌نامه با اخذ مجوز از استاد راهنما، بلامانع است.
- ☐ بهره‌برداری از این پایان‌نامه تا تاریخ ممنوع است.

استاد راهنما: دکتر آرش عبدی
هجراندوست

تاریخ:

امضا:

تقدیم به

پدر و مادر عزیزم،
که با عشق بی‌کران، صبوری و حمایت‌های همیشگی خود، همواره پشتیبان و الهام‌بخش
من در مسیر زندگی و تحصیل بوده‌اند.

استادان گرامی‌ام،
که با آموزش‌های ارزشمند، نگاه علمی دقیق و راهنمایی‌های دلسوزانه‌ی خود، زمینه‌ساز
رشد فکری و پیشرفت تحصیلی‌ام شدند.

قدردانی

با نهایت قدردانی و احترام، از استاد ارجمندم، جناب آقای دکتر آرش عبدی هجران دوست، صمیمانه سپاسگزارم که با دانش عمیق، دیدگاه‌های راهگشا و راهنمایی‌های دلسوزانه‌ی خود در تمامی مراحل انجام این پژوهش همراه و پشتیبان من بودند. بی‌تردید، این اثر حاصل حمایت‌های علمی، اعتماد و هدایت‌های ارزشمند ایشان است و بدون حضور مؤثر و حمایت‌های بی‌دریغشان، دستیابی به نتایج این تحقیق میسر نبود.

علی عطاریان

اسفند ۱۴۰۴

چکیده

تحلیل احساسات سرمایه‌گذاران به لطف پیشرفت مدل‌های مدل‌های زبانی به یکی از روش‌های اصلی استخراج اطلاعات از متون مالی تبدیل شده‌اند. روش‌های سنتی تحلیل احساسات که متون را به دسته‌های صعودی، نزولی، و خنثی طبقه‌بندی می‌کنند، اغلب محدودیت‌های زمانی و مرزهای سود و زیان را در نظر نمی‌گیرند و برای معاملات الگوریتمی کارایی لازم را ندارند. این پایان‌نامه یک روش نوآورانه برای طبقه‌بندی متون مالی ارائه می‌دهد که با برچسب‌گذاری بازارمحور، قادر به پیش‌بینی حرکات کوتاه‌مدت بازار و ارائه سیگنال‌های معاملاتی در بازار بیت‌کوین است. همچنین، از طریق مهندسی پرسش، اطلاعات قیمتی و زمانی به متن‌ها اضافه شده تا مدل زبانی از اطلاعات بازار هدف در هنگام پیش‌بینی مطلع باشد. اهمیت این یافته در این است که معمولاً مدل‌های زبانی نه تنها به تنهایی توانایی پیش‌بینی بازار را ندارند، بلکه گاهی در ترکیب با مدل‌های بر پایه قیمت نیز بهبود زیادی ایجاد نمی‌کنند. در نتیجه مدل پیشنهادی می‌تواند به عنوان جایگزینی برای تحلیل متون مالی با هدف بهبود کارایی الگوریتم‌های معاملاتی استفاده شود. روش پیشنهادی با استفاده از توییت‌های مربوط به بازار بیت‌کوین از سال‌های ۲۰۱۵ تا ۲۰۲۳ ارزیابی شد. نتایج نشان داد که مدل‌های مبتنی بر احساسات هیچگونه قدرت پیش‌بینی در تشخیص روند کوتاه‌مدت بازار ندارند، اما مدل‌های پیشنهادی در پیش‌بینی روندهای کوتاه‌مدت عملکرد بهتری داشتند. مدل تنظیم‌شده در مجموعه داده‌ای با ۲۲۷ رویداد مهم بیت‌کوین، امتیاز $F1$ معادل ۸۰.۳٪ کسب کرد و افزودن اطلاعات مربوط به بازار دقت پیش‌بینی‌ها را بهبود بخشید. پیش‌آزمون سیگنال‌های معاملاتی نشان داد که روش پیشنهادی عملکردی را نسبت به الگوریتم‌های معیار بهبود داده و در شرایط نامطمئن از سیگنال‌های بیش‌ازحد تهاجمی جلوگیری می‌کند. این روش در بازارهای صعودی به نسبت شارپ ۵.۱۰ و در بازارهای خنثی به ۳.۷۶ دست یافت. این یافته‌ها بر اهمیت برچسب‌های اختصاصی بازار و مهندسی پرسش در بهره‌گیری از مدل‌های زبانی برای پیش‌بینی بازارهای مالی تأکید دارد و رویکردی قوی‌تر نسبت به تحلیل احساسات سنتی برای معاملات الگوریتمی ارائه می‌دهد.

واژگان کلیدی: الگوریتم‌های معاملاتی، بازارهای مالی، تحلیل داده‌های متنی، تحلیل احساسات

فهرست مطالب

خ	فهرست تصاویر
د	فهرست جداول
۱	فصل ۱: مقدمه
۱	۱-۱ بیان مسئله
۴	۲-۱ روش پیشنهادی
۵	۳-۱ ساختار پایان نامه
۶	فصل ۲: مفاهیم پایه
۶	۱-۲ مدل ریاضی تخریب و بازسازی تصویر
۷	۲-۲ بازنمایی تنک و یادگیری دیکشنری
۸	۳-۲ یادگیری عمیق داده محور
۸	۴-۲ یادگیری درونی و سازگاری تصویر-ویژه
۹	۵-۲ مدل سازی تخریب پیچیده و واقع گرایی ادراکی
۱۰	۶-۲ تعاریف و نمادگذاری های متداول در ابرتفکیک
۱۱	۷-۲ معیارهای ارزیابی کمی
۱۱	۱-۷-۲ ریشه میانگین مربعات خطا
۱۱	۲-۷-۲ نسبت سیگنال به نویز بیشینه
۱۲	۳-۷-۲ شاخص شباهت ساختاری
۱۲	۸-۲ شبکه های مولد تخصصی

۹-۲	موازنه دقت عددی و کیفیت ادراکی	۱۳
۱۰-۲	ارزیابی بر روی کانال روشنایی در فضای رنگی	۱۳
۱۱-۲	معیارهای ارزیابی بدون مرجع	۱۴
۱۲-۲	روش بازافکنی سازگار	۱۵
۱۳-۲	جمع‌بندی	۱۶

۱۸	کتاب‌نامه
----	-----------

۱۹	واژه‌نامه فارسی به انگلیسی
----	----------------------------

۲۱	واژه‌نامه فارسی به انگلیسی
----	----------------------------

فهرست تصاویر

فهرست جداول

فصل ۱

مقدمه

۱-۱ بیان مسئله

افزایش وضوح تصویر تک تصویری یکی از مسائل بنیادی در پردازش تصویر و بینایی ماشین است که طی دو دهه اخیر به دلیل گسترش کاربردهای عملی آن، توجه گسترده‌ای را به خود جلب کرده است. در بسیاری از سامانه‌های تصویربرداری، از جمله دوربین‌های تلفن همراه، سامانه‌های نظارتی، تصاویر تاریخی اسکن شده، تصاویر پزشکی و داده‌های سنجش از دور، محدودیت‌های سخت‌افزاری، فاصله از سوژه، محدودیت پهنای باند انتقال داده یا شرایط محیطی موجب می‌شود تنها نسخه‌ای با وضوح پایین از تصویر در دسترس باشد. در چنین شرایطی، بازسازی تصویری با وضوح بالاتر که از نظر ساختاری و ادراکی به واقعیت نزدیک باشد، اهمیت فراوانی می‌یابد. [۲]

مسئله ابرتفکیک تک تصویری ذاتاً بدوضع^۱ است. علت این امر آن است که فرآیند تولید تصویر با وضوح پایین، اطلاعات فرکانسی بالا را از بین می‌برد و بنابراین بازگرداندن این اطلاعات بدون در اختیار داشتن قیود پیشین مناسب، امکان‌پذیر نیست. مدل عمومی تخریب تصویر را می‌توان به صورت زیر بیان کرد: [۱]

$$\mathbf{y} = (\mathbf{x} \otimes \mathbf{k}) \downarrow_s + \mathbf{n} \quad (1-1)$$

¹Ill-posed

که در آن x تصویر با وضوح بالا، k کرنل تاری، $\otimes$ عملگر کانولوشن، $\downarrow_s$ عملگر نمونه برداری با ضریب مقیاس s و n نویز افزوده است. در قالبی خطی تر، این رابطه را می توان به شکل زیر نیز نوشت:

$$y = Dx + n \quad (۲-۱)$$

که در آن D عملگر ترکیبی تاری و کاهش نمونه برداری است. هدف ابرتفکیک، تخمین x از روی مشاهده y است. با توجه به اینکه عملگر D معمولاً رتبه کامل ندارد و بخشی از اطلاعات را حذف می کند، این مسئله فاقد جواب یکتا بوده و نیازمند استفاده از پیشین های ساختاری یا آماری است. یکی از رویکردهای مهم در این حوزه، بهره گیری از نمایش تنک^۲ است. در این چارچوب فرض می شود هر قطعه کوچک از تصویر را می توان به صورت ترکیب خطی تعداد اندکی اتم از یک دیکشنری مناسب بیان کرد. اگر y یک پچ با وضوح پایین و D_l دیکشنری متناظر باشد، مسئله یافتن ضرایب تنک به شکل زیر بیان می شود:

$$\alpha^* = \arg \min_{\alpha} \|y - D_l \alpha\|_2^2 + \lambda \|\alpha\|_1 \quad (۳-۱)$$

فرض کلیدی در این رویکرد آن است که همین ضرایب α^* را می توان برای بازسازی پچ متناظر در فضای وضوح بالا نیز به کار برد:

$$x = D_h \alpha^* \quad (۴-۱)$$

که در آن D_h دیکشنری فضای وضوح بالا است. این ایده نشان داد که تنکی یک پیشین قدرتمند برای مدل سازی ساختارهای طبیعی تصویر است. با این حال، حل مسائل بهینه سازی تنک برای تمامی پچ های تصویر، هزینه محاسباتی قابل توجهی دارد و در کاربردهای بزرگ مقیاس به چالشی جدی تبدیل می شود.

²Sparse Representation

با پیشرفت یادگیری عمیق، شبکه‌های کانولوشنی بسیار عمیق که بر روی پایگاه داده‌های بزرگ آموزش دیده‌اند، عملکرد ابرتفکیک را به شکل چشمگیری بهبود بخشیدند. این روش‌ها به صورت داده‌محور، نگاشت میان تصویر با وضوح پایین و بالا را می‌آموزند و در شرایطی که مدل تخریب مشخص و ایده‌آل باشد، به نتایج درخشانی دست می‌یابند. در اغلب این مطالعات، تصویر با وضوح پایین از طریق یک کرنل نمونه‌برداری مشخص و بدون حضور نویز یا مصنوعات دیگر تولید می‌شود.

با این حال، همان‌گونه که در پژوهش‌های اخیر نشان داده شده است، تصاویر دنیای واقعی به ندرت از چنین مدل تخریب ایده‌آلی تبعیت می‌کنند. در عمل، تصویر ممکن است تحت تأثیر تارگی، خطاهای فوکوس، نویز حسگر، فشرده‌سازی با اتلاف، تقویت بیش از حد لبه‌ها یا اشتراک‌گذاری چندباره در شبکه‌های اجتماعی قرار گرفته باشد. این فرآیند تخریب را می‌توان به صورت یک ترکیب چندمرحله‌ای مدل کرد:

$$y = C_2(D_2(C_1(D_1(x)))) + n \quad (5-1)$$

که در آن D_i عملیات تارگی و کاهش نمونه‌برداری و C_i فرآیندهای فشرده‌سازی یا پردازش‌های غیرخطی را مدل می‌کنند. این دیدگاه که تحت عنوان تخریب مرتبه بالا^۳ مطرح شده است، نشان می‌دهد فاصله قابل توجهی میان داده‌های مصنوعی مورد استفاده در آموزش و تصاویر واقعی وجود دارد.

در پاسخ به این چالش، رویکردهای مبتنی بر شبکه‌های مولد تخصصی^۴ مطرح شدند که هدف آن‌ها نه تنها کاهش خطای بازسازی عددی، بلکه افزایش واقع‌گرایی ادراکی تصویر خروجی است. در این چارچوب، یک شبکه مولد تلاش می‌کند تصویر با وضوح بالا را بازسازی کند، در حالی که یک شبکه تمایزبخش کیفیت و طبیعی بودن خروجی را ارزیابی می‌کند. نسخه‌های توسعه یافته‌ای مانند روش تقویت شده برای تصاویر واقعی^۵ با در نظر گرفتن مدل‌های تخریب پیچیده‌تر و طراحی ساختارهای پایدارتر برای آموزش، سعی در کاهش فاصله میان داده‌های مصنوعی و تصاویر دنیای واقعی داشته‌اند. این رویکردها نشان می‌دهند که علاوه بر دقت بازسازی، کیفیت ادراکی و سازگاری با شرایط غیرایده‌آل نیز به مؤلفه‌ای کلیدی در ارزیابی سامانه‌های ابرتفکیک تبدیل شده است.

در سوی دیگر، رویکرد یادگیری درونی^۶ با تکیه بر خاصیت بازگشت‌پذیری چندمقیاسی در تصاویر طبیعی،

³High-Order Degradation

⁵Real-ESRGAN+

⁴Generative Adversarial Networks

⁶Internal Learning

پیشنهاد می‌کند که نمونه‌های آموزشی مورد نیاز برای یادگیری نگاشت وضوح پایین به بالا را می‌توان مستقیماً از خود تصویر استخراج کرد. این ایده مبنای روش ابرتفکیک بدون آموزش پیشین^۷ است که در آن یک شبکه کوچک در زمان آزمون و تنها با استفاده از نمونه‌های استخراج‌شده از تصویر ورودی آموزش داده می‌شود و به صورت تصویر-ویژه با شرایط تخریب سازگار می‌گردد.

در نتیجه، مسئله ابرتفکیک تک‌تصویری در ادبیات پژوهش را می‌توان در تعامل میان سه محور اساسی تحلیل کرد: بهره‌گیری از پیشین‌های ساختاری مانند تنکی، استفاده از مدل‌های یادگیری عمیق داده‌محور و توجه به واقع‌گرایی ادراکی و مدل‌سازی دقیق تخریب در تصاویر واقعی. با وجود پیشرفت‌های چشمگیر در هر یک از این محورها، همچنان چالش‌هایی نظیر پیچیدگی محاسباتی بالا، هزینه آموزش، و شکاف میان داده‌های مصنوعی و شرایط عملی وجود دارد. از این رو، بازنگری در ساختار محاسباتی و بهینه‌سازی روش‌های موجود، در حالی که بنیان نظری آن‌ها حفظ شود، گامی ضروری در جهت کاربردی‌سازی مؤثر این فناوری‌ها به شمار می‌آید.

۲-۱ روش پیشنهادی

در این پژوهش، تمرکز اصلی بر بهبود کارایی دو رویکرد مطرح در ابرتفکیک، یعنی روش مبتنی بر نمایش تنک و روش مبتنی بر یادگیری درونی بوده است.

در بهبود روش مبتنی بر نمایش تنک، چارچوب اصلی حفظ شده اما فرآیند حل مسئله بازنمایی تنک بازطراحی شده است. به جای استفاده از روش‌های بهینه‌سازی تکراری پرهزینه، از یک راهبرد انتخاب تدریجی اتم‌های مؤثر استفاده شده است که در هر مرحله مناسب‌ترین اتم را بر اساس شباهت به باقیمانده انتخاب می‌کند. همچنین ساختار استخراج ویژگی و نحوه پردازش قطعه‌های تصویر به گونه‌ای بازآرایی شده که محاسبات تکراری کاهش یابد و پیاده‌سازی کارآمدتری حاصل شود.

در بهبود روش مبتنی بر یادگیری درونی نیز چارچوب کلی آموزش شبکه تصویر-ویژه حفظ شده است، اما سازوکار کنترل فرآیند آموزش بازتنظیم شده است. با اصلاح سیاست توقف، بازطراحی نحوه نمونه‌برداری از تصویر و تنظیم راهبرد به‌روزرسانی نرخ یادگیری، فرآیند آموزش پایدارتر و کارآمدتر شده است، بدون آنکه اصول بنیادین یادگیری درونی تغییر یابد.

⁷Zero-Shot Super-Resolution

هدف از این اصلاحات، دستیابی به تعادلی مناسب میان کیفیت بازسازی و کارایی محاسباتی، در چارچوب همان مدل‌های پایه بوده است.

۱-۳ ساختار پایان نامه

این پایان نامه در پنج فصل تنظیم شده است. در فصل اول، بیان مسئله، انگیزه پژوهش و معرفی کلی روش پیشنهادی ارائه شد.

فصل دوم به بررسی و تشریح مفاهیم پایه، مبانی نظری و پیشینه پژوهش اختصاص دارد. در این فصل، اصول نمایش تنک، مفاهیم یادگیری عمیق، ساختار شبکه‌های کانولوشنی، یادگیری درونی، مدل‌های تخریب تصویر و معیارهای ارزیابی کیفیت بازسازی به صورت نظام‌مند مرور می‌شوند تا چارچوب نظری لازم برای فصول بعد فراهم گردد.

در فصل سوم، روش‌های پایه مورد استفاده در این پژوهش به صورت دقیق معرفی و تحلیل می‌شوند و پیاده‌سازی آن‌ها مورد بررسی قرار می‌گیرد.

فصل چهارم به ارائه بهبودهای پیشنهادی، تحلیل مقایسه‌ای و ارزیابی تجربی نتایج اختصاص دارد. در نهایت، فصل پنجم شامل جمع‌بندی، نتیجه‌گیری و پیشنهادهایی برای پژوهش‌های آینده است.

فصل ۲

مفاهیم پایه

در این فصل، مبانی نظری و چارچوب‌های اصلی مورد استفاده در مسئله ابرتفکیک تک‌تصویری مورد بررسی قرار می‌گیرد. هدف این فصل، فراهم‌سازی زمینه‌ای منسجم برای درک روش‌های مورد مطالعه و تحلیل دقیق‌تر آن‌ها در فصول بعدی است.

۱-۲ مدل ریاضی تخریب و بازسازی تصویر

همان‌گونه که در فصل قبل اشاره شد، مسئله ابرتفکیک را می‌توان به صورت معکوس‌سازی یک فرآیند تخریب مدل‌سازی کرد. مدل کلاسیک تخریب به صورت زیر بیان می‌شود:

$$\mathbf{y} = (\mathbf{x} \otimes \mathbf{k}) \downarrow_s + \mathbf{n} \quad (1-2)$$

که در آن $\mathbf{x}$ تصویر با وضوح بالا، $\mathbf{k}$ کرنل تاری، $\downarrow_s$ عملگر کاهش نمونه‌برداری با ضریب s و $\mathbf{n}$ نویز افزوده است. در قالب ماتریسی، این رابطه به شکل زیر بازنویسی می‌شود:

$$\mathbf{y} = \mathbf{D}\mathbf{x} + \mathbf{n} \quad (2-2)$$

از آنجا که عملگر D اطلاعات فرکانسی بالا را حذف می‌کند، بازیابی x از روی y نیازمند تعریف پیشین مناسب است. انتخاب این پیشین، هسته اصلی تفاوت میان روش‌های مختلف ابرتفکیک را تشکیل می‌دهد.

۲-۲ بازنمایی تنک و یادگیری دیکشنری

یکی از تأثیرگذارترین چارچوب‌های کلاسیک در ابرتفکیک، مبتنی بر بازنمایی تنک^۱ است. فرض اساسی در این رویکرد آن است که هر پچ تصویر را می‌توان به صورت ترکیب خطی تعداد اندکی اتم از یک دیکشنری بیان کرد.

برای یک پچ وضوح پایین y و دیکشنری D_l ، مسئله بهینه‌سازی به شکل زیر تعریف می‌شود:

$$\alpha^* = \arg \min_{\alpha} \|y - D_l \alpha\|_2^2 + \lambda \|\alpha\|_1 \quad (۳-۲)$$

که در آن λ پارامتر تنظیم‌کننده تنکی است. فرض کلیدی این روش آن است که ضرایب تنک به دست آمده در فضای وضوح پایین، در فضای وضوح بالا نیز معتبر هستند:

$$x = D_h \alpha^* \quad (۴-۲)$$

که D_h دیکشنری متناظر در فضای وضوح بالا است.

حل این مسئله معمولاً از طریق الگوریتم‌های بهینه‌سازی محدب یا روش‌های حریصانه انجام می‌شود. پیچیدگی محاسباتی و نیاز به حل مسئله برای تمامی پچ‌های تصویر، از چالش‌های اساسی این چارچوب به شمار می‌آید.

^۱Sparse Representation

۲-۳ یادگیری عمیق داده‌محور

با ظهور شبکه‌های کانولوشنی عمیق^۲، مسئله ابرتفکیک به‌صورت یادگیری یک نگاشت غیرخطی از فضای تصاویر وضوح پایین به فضای وضوح بالا مدل شد:

$$\mathbf{x} = f_{\theta}(\mathbf{y}) \quad (2-5)$$

که در آن f_{θ} شبکه‌ای با پارامترهای θ است که از طریق کمینه‌سازی تابع زیان زیر آموزش داده می‌شود:

$$\mathcal{L}(\theta) = \mathbb{E} \left[\|f_{\theta}(\mathbf{y}) - \mathbf{x}\|_p \right] \quad (2-6)$$

این روش‌ها با استفاده از داده‌های گسترده خارجی آموزش دیده و قادر به مدل‌سازی روابط پیچیده میان الگوهای وضوح پایین و بالا هستند. با این حال، عملکرد آن‌ها به‌شدت وابسته به سازگاری مدل تخریب داده‌های آموزشی با داده‌های آزمون است.

۲-۴ یادگیری درونی و سازگاری تصویر-ویژه

در مقابل رویکردهای آموزش دیده بر داده‌های خارجی، چارچوب یادگیری درونی^۳ بر این اصل استوار است که تصاویر طبیعی دارای بازگشت‌پذیری آماری درونی در مقیاس‌های مختلف هستند. به بیان دیگر، قطعات کوچک تصویر در سطوح مقیاس متفاوت تکرار می‌شوند.

در این چارچوب، مجموعه آموزش مستقیماً از خود تصویر استخراج شده و شبکه‌ای کوچک در زمان آزمون آموزش داده می‌شود. این شبکه نگاشت تصویر-ویژه را می‌آموزد:

²Convolutional Neural Networks

³Internal Learning

$$\mathbf{x} = f_{\theta_I}(\mathbf{y}) \quad (۷-۲)$$

که در آن پارامترهای θ_I برای هر تصویر به صورت مستقل یاد گرفته می شوند. این سازگاری تصویر-محور امکان عملکرد مناسب در شرایط تخریب ناشناخته و غیرایده آل را فراهم می سازد.

۵-۲ مدل سازی تخریب پیچیده و واقع گرایی ادراکی

یکی از محدودیت های اساسی مدل های کلاسیک، ساده سازی بیش از حد فرآیند تخریب است. در تصاویر واقعی، تخریب اغلب شامل چندین مرحله متوالی از تاری، نویز، تغییر اندازه، فشرده سازی و پردازش های غیرخطی است. این فرآیند را می توان به صورت زیر مدل کرد:

$$\mathbf{y} = \mathcal{D}_n(\mathcal{D}_{n-1}(\dots \mathcal{D}_1(\mathbf{x}))) \quad (۸-۲)$$

که در آن هر $\mathcal{D}_i$ یک مرحله تخریب با پارامترهای مستقل است. این چارچوب که به مدل تخریب مرتبه بالا^۴ شناخته می شود، فضای وسیع تری از شرایط واقعی را پوشش می دهد. برای مقابله با این پیچیدگی، شبکه های مولد تخصصی^۵ مورد استفاده قرار گرفتند. در این ساختار، یک شبکه مولد G تصویر ابرتفکیک شده را تولید می کند و یک شبکه تمایزبخش D کیفیت ادراکی آن را ارزیابی می نماید:

$$\min_G \max_D \mathbb{E}_{\mathbf{x}}[\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{y}}[\log(1 - D(G(\mathbf{y})))] \quad (۹-۲)$$

نسخه های پیشرفته تر این چارچوب با طراحی ساختارهای عمیق تر برای مولد و تمایزبخش، و همچنین با

^۴High-Order Degradation

^۵Generative Adversarial Networks

مدل‌سازی دقیق‌تر فرآیندهای تخریب پیچیده، تلاش کرده‌اند شکاف میان داده‌های مصنوعی و تصاویر واقعی را کاهش دهند. استفاده از ساختارهای باقیمانده درون باقیمانده^۶ در مولد و تمایزبخش‌های مبتنی بر ساختار U شکل با نرمال‌سازی طیفی، نمونه‌ای از این پیشرفت‌ها است.

۲-۶ تعاریف و نمادگذاری‌های متداول در ابرتفکیک

در ادبیات ابرتفکیک، از مجموعه‌ای از نمادگذاری‌ها و اصطلاحات استاندارد استفاده می‌شود که درک دقیق آن‌ها برای تحلیل روش‌ها ضروری است. در این پژوهش نیز از همین قراردادها پیروی می‌شود. تصویر با وضوح پایین با نماد y و عنوان^۷ نمایش داده می‌شود. تصویر مرجع با وضوح بالا که به عنوان حقیقت مبنا در ارزیابی استفاده می‌شود، با نماد x یا x_{gt} و عنوان^۸ یا^۹ شناخته می‌شود. خروجی الگوریتم ابرتفکیک با نماد $\hat{x}$ نمایش داده شده و به آن تصویر^{۱۰} گفته می‌شود. رابطه کلی میان این کمیت‌ها را می‌توان به صورت زیر خلاصه کرد:

$$\hat{x} = \mathcal{F}(y) \quad (2-10)$$

که در آن $\mathcal{F}$ مدل یا الگوریتم ابرتفکیک است. در ارزیابی کمی، هدف آن است که فاصله میان $\hat{x}$ و x_{gt} کمینه شود.

ضریب بزرگ‌نمایی معمولاً با s نمایش داده می‌شود، به طوری که:

$$\dim(x_{gt}) = s \times \dim(y) \quad (2-11)$$

مقادیر رایج برای s برابر ۲، ۳ یا ۴ هستند.

^۶Residual-in-Residual Dense Blocks

^۷Low-Resolution (LR)

^۸High-Resolution (HR)

^۹Ground Truth (GT)

^{۱۰}Super-Resolved (SR)

۷-۲ معیارهای ارزیابی کمی

ارزیابی عملکرد روش‌های ابرتفکیک معمولاً با استفاده از معیارهای کمی مبتنی بر فاصله پیکسلی یا شباهت ساختاری انجام می‌شود.

۱-۷-۲ ریشه میانگین مربعات خطا

یکی از ساده‌ترین معیارها، ریشه میانگین مربعات خطا^{۱۱} است که به صورت زیر تعریف می‌شود:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{x}_i - x_{gt,i})^2} \quad (۱۲-۲)$$

که در آن N تعداد کل پیکسل‌ها است. این معیار اختلاف مطلق شدت پیکسل‌ها را اندازه‌گیری می‌کند، اما همبستگی آن با ادراک بصری انسان محدود است.

۲-۷-۲ نسبت سیگنال به نویز بیشینه

معیار پرکاربرد دیگر، نسبت سیگنال به نویز بیشینه^{۱۲} است که بر پایه میانگین مربعات خطا تعریف می‌شود:

$$\text{PSNR} = 10 \log_{10} \left(\frac{L^2}{\text{MSE}} \right) \quad (۱۳-۲)$$

که در آن:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (\hat{x}_i - x_{gt,i})^2 \quad (۱۴-۲)$$

^{۱۱}Root Mean Square Error (RMSE)

^{۱۲}Peak Signal-to-Noise Ratio (PSNR)

و L بیشینه مقدار شدت پیکسل (برای تصاویر ۸ بیتی برابر ۲۵۵) است. مقدار بزرگ‌تر PSNR نشان‌دهنده بازسازی نزدیک‌تر به تصویر مرجع است.

۲-۷-۳ شاخص شباهت ساختاری

به منظور لحاظ کردن ویژگی‌های ادراکی، شاخص شباهت ساختاری^{۱۳} معرفی شد. این معیار سه مؤلفه روشنایی، کنتراست و ساختار را مقایسه می‌کند:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2-15)$$

که در آن μ میانگین، σ^2 واریانس و σ_{xy} کوواریانس دو تصویر است. SSIM مقداری بین صفر و یک دارد و مقادیر نزدیک به یک نشان‌دهنده شباهت ساختاری بیشتر هستند.

۲-۸ شبکه‌های مولد تخصصی

شبکه‌های مولد تخصصی^{۱۴} چارچوبی برای یادگیری توزیع داده‌ها از طریق رقابت میان دو شبکه عصبی هستند. این چارچوب شامل یک مولد G و یک تمایزبخش D است. مولد تلاش می‌کند نمونه‌هایی تولید کند که از نظر آماری مشابه داده‌های واقعی باشند، در حالی که تمایزبخش تلاش می‌کند نمونه‌های واقعی و تولیدی را از یکدیگر تفکیک کند. مسئله بهینه‌سازی به صورت زیر تعریف می‌شود:

$$\min_G \max_D \mathbb{E}_{\mathbf{x} \sim p_{data}} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{y}} [\log(1 - D(G(\mathbf{y})))] \quad (2-16)$$

در ابرتفکیک، مولد نگاشت $\mathbf{y} \rightarrow \hat{\mathbf{x}}$ را می‌آموزد و تمایزبخش کیفیت ادراکی خروجی را ارزیابی می‌کند. برخلاف روش‌های صرفاً مبتنی بر خطای پیکسلی، استفاده از GAN موجب افزایش واقع‌گرایی بافت‌ها و

¹³Structural Similarity Index (SSIM)

¹⁴Generative Adversarial Networks (GANs)

جزئیات ریز می‌شود، هرچند ممکن است مقدار PSNR کاهش یابد. در نسخه‌های پیشرفته‌تر، علاوه بر زیان تخصصی، از زیان ادراکی^{۱۵} مبتنی بر ویژگی‌های استخراج شده از شبکه‌های ازپیش‌آموزش دیده نیز استفاده می‌شود:

$$\mathcal{L}_{perc} = \|\phi(\hat{\mathbf{x}}) - \phi(\mathbf{x}_{gt})\|_2^2 \quad (2-17)$$

که در آن ϕ نگاشت ویژگی در یک شبکه عمیق ثابت است.

۲-۹ موازنه دقت عددی و کیفیت ادراکی

یکی از مباحث مهم در ابرتفکیک، تضاد میان بیشینه‌سازی معیارهای عددی مانند PSNR و بهبود کیفیت ادراکی است. کمینه‌سازی خطای مربعی منجر به خروجی‌های نرم و میانگین‌گرا می‌شود، در حالی که بهینه‌سازی مبتنی بر GAN تمایل به تولید بافت‌های تیزتر اما گاه غیرمنطبق با مقدار دقیق پیکسلی دارد. این تعادل را می‌توان به صورت ترکیب چند تابع زیان مدل کرد:

$$\mathcal{L}_{total} = \lambda_1 \mathcal{L}_{pixel} + \lambda_2 \mathcal{L}_{perc} + \lambda_3 \mathcal{L}_{adv} \quad (2-18)$$

که در آن ضرایب λ_i وزن هر مؤلفه را تعیین می‌کنند.

۲-۱۰ ارزیابی بر روی کانال روشنایی در فضای رنگی

در بسیاری از مقالات ابرتفکیک، ارزیابی کمی به جای انجام در فضای رنگی^{۱۶}، بر روی کانال روشنایی در فضای^{۱۷} انجام می‌شود. دلیل این انتخاب به نحوه ادراک سیستم بینایی انسان بازمی‌گردد. فضای YCbCr تصویر را به سه مؤلفه تفکیک می‌کند:

¹⁵ Perceptual Loss

¹⁷ YCbCr

¹⁶ RGB

- مؤلفه روشنایی Y

- مؤلفه اختلاف آبی Cb

- مؤلفه اختلاف قرمز Cr

سیستم بینایی انسان حساسیت بیشتری نسبت به تغییرات روشنایی نسبت به تغییرات رنگی دارد. به همین دلیل، بسیاری از روش‌های ابرتفکیک تنها کانال Y را بازسازی کرده و کانال‌های رنگی را با روش‌های ساده‌تر مانند درونیابی بزرگ‌نمایی می‌کنند.

رابطه تبدیل از RGB به YCbCr به صورت خطی بیان می‌شود:

$$Y = 0.299R + 0.587G + 0.114B \quad (2-19)$$

در ارزیابی کمی، ابتدا تصاویر به فضای YCbCr تبدیل شده و سپس معیارهایی مانند PSNR و SSIM تنها بر روی کانال Y محاسبه می‌شوند:

$$\text{PSNR}_Y = 10 \log_{10} \left(\frac{L^2}{\text{MSE}(Y)} \right) \quad (2-20)$$

این رویکرد باعث می‌شود نتایج عددی با ادراک بصری انسان همبستگی بیشتری داشته باشند و همچنین مقایسه عادلانه‌تری میان روش‌هایی که تنها روشنایی را مدل می‌کنند فراهم گردد.

۲-۱۱ معیارهای ارزیابی بدون مرجع

معیارهایی مانند PSNR و SSIM نیازمند در اختیار داشتن تصویر مرجع^{۱۸} هستند. با این حال، در بسیاری از کاربردهای واقعی، تصویر وضوح بالا در دسترس نیست. در چنین شرایطی از معیارهای بدون مرجع^{۱۹} استفاده می‌شود.

¹⁸Ground Truth

¹⁹No-Reference Image Quality Assessment

یکی از پرکاربردترین این معیارها، شاخص کیفیت طبیعی تصویر^{۲۰} است. ایده اصلی NIQE بر این فرض استوار است که تصاویر طبیعی دارای توزیع آماری مشخصی در حوزه ویژگی‌های آماری هستند. در این روش، ویژگی‌هایی مبتنی بر مدل آماری گوسی تعمیم‌یافته^{۲۱} از تصویر استخراج شده و با یک مدل آماری آموزش‌دیده از تصاویر طبیعی مقایسه می‌شوند. فاصله آماری میان این دو توزیع به‌عنوان معیار کیفیت تعریف می‌شود:

$$NIQE = \sqrt{(\mu - \mu_n)^T \Sigma^{-1} (\mu - \mu_n)} \quad (2-21)$$

که در آن μ و Σ میانگین و کوواریانس ویژگی‌های تصویر ارزیابی‌شده و μ_n و Σ_n پارامترهای مدل تصاویر طبیعی هستند.

برخلاف PSNR، NIQE مقدار کمتر نشان‌دهنده کیفیت بهتر است. این معیار به‌ویژه در ارزیابی روش‌های مبتنی بر شبکه‌های مولد که تمرکز بر کیفیت ادراکی دارند، اهمیت زیادی پیدا می‌کند.

۲-۱۲ روش بازافکنی سازگار

یکی از تکنیک‌های کلاسیک برای بهبود سازگاری نتیجه ابرتفکیک با مدل تخریب، روش بازافکنی^{۲۲} است. ایده اصلی این روش آن است که تصویر بازسازی‌شده باید پس از اعمال مدل تخریب، مجدداً تصویر وضوح پایین اولیه را تولید کند.

اگر $\hat{x}$ خروجی اولیه الگوریتم باشد، می‌توان آن را از طریق مدل تخریب به وضوح پایین بازگرداند:

$$y' = D\hat{x} \quad (2-22)$$

اختلاف میان y' و تصویر ورودی y برابر است با:

²⁰Natural Image Quality Evaluator (NIQE)

²²Back-Projection

²¹Generalized Gaussian Model

$$\mathbf{e} = \mathbf{y} - \mathbf{y}' \quad (2-23)$$

این خطا سپس به فضای وضوح بالا بازافکنی شده و برای اصلاح تصویر استفاده می شود:

$$\hat{\mathbf{x}}^{(t+1)} = \hat{\mathbf{x}}^{(t)} + \mathbf{D}^T \mathbf{e} \quad (2-24)$$

که $\mathbf{D}^T$ عملگر معکوس تقریبی (ترانهاده) مدل تخریب است. این فرآیند به صورت تکراری اجرا می شود تا سازگاری میان تصویر SR و تصویر LR اولیه برقرار گردد. روش بازافکنی به ویژه در شرایطی که مدل تخریب شناخته شده یا تخمین زده شده باشد، موجب بهبود دقت عددی و کاهش مصنوعات ناخواسته می شود. بسیاری از روش های مدرن، حتی در چارچوب یادگیری عمیق، از این ایده به صورت یک مرحله اصلاح نهایی بهره می برند.

۱۳-۲ جمع بندی

در این فصل، چارچوب نظری و مفاهیم پایه مورد نیاز برای تحلیل مسئله ابرتفکیک تک تصویری به صورت منسجم مورد بررسی قرار گرفت. ابتدا مدل ریاضی تخریب تصویر و ماهیت بدوضع این مسئله تشریح شد و نشان داده شد که بازیابی تصویر با وضوح بالا مستلزم بهره گیری از پیشین های مناسب یا یادگیری نگاشت های پیچیده غیرخطی است.

در ادامه، سه جریان اصلی در توسعه روش های ابرتفکیک معرفی گردید: رویکردهای مبتنی بر بازنمایی تنک و یادگیری دیکشنری، روش های داده محور مبتنی بر شبکه های کانولوشنی عمیق، و چارچوب های تصویر-ویژه مبتنی بر یادگیری درونی. همچنین مدل سازی تخریب های پیچیده و مرتبه بالا و نقش شبکه های مولد تخصصی در بهبود کیفیت ادراکی و بازسازی بافت های واقع گرایانه مورد بررسی قرار گرفت. نشان داده شد که این رویکردها در تعامل با یکدیگر شکل گرفته اند و هر یک بخشی از چالش های مسئله را هدف قرار می دهند. علاوه بر مبانی مدل سازی، نمادگذاری های استاندارد در حوزه ابرتفکیک شامل تصاویر وضوح پایین،

وضوح بالا، خروجی بازسازی‌شده و تصویر مرجع معرفی گردید تا چارچوبی دقیق برای تحلیل‌های بعدی فراهم شود. سپس معیارهای ارزیابی کمی مانند PSNR، RMSE و SSIM تشریح شدند و تفاوت آن‌ها از منظر دقت پیکسلی و شباهت ساختاری تبیین گردید. همچنین اهمیت ارزیابی بر روی کانال روشنایی در فضای رنگی YCbCr و دلیل ترجیح آن در ادبیات پژوهش توضیح داده شد.

در ادامه، محدودیت معیارهای مرجع‌دار در سناریوهای واقعی مطرح و شاخص‌های بدون مرجع نظیر NIQE معرفی شدند که امکان ارزیابی کیفیت ادراکی در غیاب تصویر حقیقت مبنا را فراهم می‌کنند. همچنین مفهوم بازافکنی سازگار به‌عنوان مکانیزمی برای تضمین انطباق خروجی ابرتفکیک با مدل تخریب اولیه بررسی شد.

برآیند مباحث این فصل نشان می‌دهد که مسئله ابرتفکیک تنها یک مسئله بازسازی عددی ساده نیست، بلکه تعادلی میان مدل‌سازی دقیق تخریب، بهره‌گیری از پیشین‌های آماری یا ساختاری، یادگیری نگاشت‌های پیچیده و ارزیابی چندبعدی کیفیت را طلب می‌کند. این چارچوب نظری زمینه لازم برای بررسی، تحلیل و بهبود روش‌های منتخب در فصول آتی را فراهم می‌سازد.

کتاب نامه

- [1] WANG, X., YU, K., WU, S., GU, J., LIU, Y., DONG, C., LOY, C. C., QIAO, Y., AND TANG, X. Esrgan: Enhanced super-resolution generative adversarial networks, 2018.
- [2] WANG, X., YU, K., WU, S., GU, J., LIU, Y., DONG, C., QIAO, Y., AND CHANGE LOY, C. Esrgan: Enhanced super-resolution generative adversarial networks. in *European Conference on Computer Vision Workshops (ECCVW)* (2018).

واژه‌نامه فارسی به انگلیسی

Activation Function	تابع فعال‌سازی
Adam Optimizer	بهینه‌ساز آدام
Aggregation Method	روش تجميع
Algorithm	الگوریتم
AUC (Area Under Curve)	مساحت زیر منحنی
Backpropagation	پس‌انتشار خطا
Backtesting	پیش‌آزمون
Bidirectional Encoder Representations from Transformers (BERT)	بازنمایی دوطرفه رمزگذار از تبدیل‌گرها
Bitcoin	بیت‌کوین
Bias	سوگیری
Bullish	صعودی
Bearish	نزولی
Confusion Matrix	ماتریس اغتشاش
Cross-Entropy Loss	تابع زیان آنترپی متقاطع
CryptoBERT	کریپتوبرت
Data Augmentation	افزایش داده
Data Overlap	هم‌پوشانی داده
Dynamic Threshold	آستانه پویا
Ensemble Learning	یادگیری جمعی
Event-Sampled Data	داده نمونه‌برداری شده از رویداد
Explainability	توضیح‌پذیری
Feature Importance	اهمیت ویژگی
Fine-tuning	تنظیم دقیق
Forward Propagation	پیش‌انتشار
Grouped Cross-Validation	اعتبارسنجی متقاطع گروه‌بندی‌شده

Hyperparameter	فراپارامتر
Labeled Dataset	مجموعه داده برچسب‌دار
Learning Rate	نرخ یادگیری
Loss Function	تابع زیان
Majority Voting	رای‌گیری اکثریت
Market Context	زمینه بازار
Market Signal	سیگنال بازار
Mean Aggregation	تجمع میانگین
Momentum	مومنتوم
Next-Day Prediction	پیش‌بینی روز بعد
Overfitting	بیش‌برازش
Performance Measure	معیار عملکرد
Pooling	پولینگ
Preprocessing	پیش‌پردازش
Prompt Engineering	مهندسی پرسش
Prompt Fine-Tuning	تنظیم دقیق پرسش
ROC (Rate of Change)	نرخ تغییر
Sentiment Analysis	تحلیل احساسات
Sentiment Ratio	نسبت احساسات
Sharpe Ratio	نسبت شارپ
Signal Aggregation	تجمع سیگنال
Softmax	نرم‌ماکس
Sortino Ratio	نسبت سورتینو
Stochastic Gradient Descent (SGD)	نزول گرادیان تصادفی
Temporal Context	زمینه زمانی
Tokenization	نشانه‌گذاری
Trading Signal	سیگنال معاملاتی
Transformer-based Model	مدل مبتنی بر تبدیل‌گر
Triple Barrier Labeling (TBL)	برچسب‌گذاری سه‌مانع
Undersampling	زیرنمونه‌برداری
Validation Set	مجموعه اعتبارسنجی
Volatility	نوسان

واژه‌نامه فارسی به انگلیسی

Dynamic Threshold	آستانه پویا
Fine-tuning	آموزش دقیق
Evaluation Tool	ابزار ارزیابی
Sentiments	احساسات
Data Overlap	اختلال داده
Bidirectional Relationship	ارتباط دوسویه
Algorithm	الگوریتم
Feature Selection	انتخاب ویژگی
Feature Importance	اهمیت ویژگی
Bidirectional Encoder Representations from Transformers	بازنمایی دوطرفه رمزگذار از تبدیل‌گرها
Bitcoin	بیتکوین
Backpropagation	پس‌انتشار خطا
Backtesting	پیش‌آزمون
Next-Day Prediction	پیش‌بینی روز بعد
Signal Aggregation	تجمع سیگنال
Sentiment Analysis	تحلیل احساسات
Ensemble Decision-Making	تصمیم‌گیری جمعی
Prompt Fine-Tuning	تنظیم دقیق پرسش
Stochastic Gradient Descent (SGD)	تنظیم گرادیان تصادفی
Tokenization	توکن‌گذاری
Model Output	خروجی مدل
Overfitting Error	خطای بیش‌برازش
Event-Sampled Data	داده نمونه‌برداری شده از رویداد
Majority Voting	رای‌گیری اکثریت
Aggregation Method	روش تجمع
Undersampling	زیرنمونه‌برداری

Market Context	زمینه بازار
Trading Signal	سیگنال معاملاتی
Market Signal	سیگنال بازار
Sharpe Ratio	شارپ نسبت
Data Augmentation	فرآیند افزایش داده
Explainability	قابلیت توضیح‌پذیری
Confusion Matrix	ماتریس اغتشاش
Labeled Dataset	مجموعه داده برچسب‌دار
Transformer-Based Model	مدل مبتنی بر تبدیل‌گر
Prompt Engineering	مهندسی پرسش
Rate of Change (ROC)	نرخ تغییر
Sentiment Ratio	نسبت احساسات
Sortino Ratio	نسبت سورتینو
Sharpe Ratio	نسبت شارپ
Softmax	نرم‌ماکس
Tokenization	نشانه‌گذاری
Volatility	نوسان
Loss Function Cost	هزینه تابع زیان

Abstract:

Investor sentiment analysis has emerged as a popular approach to extracting actionable insights from financial text, leveraging advances in language models. To infer market movements, traditional sentiment analysis often categorizes text as bullish, bearish, or neutral. Still, these classifications lack precision, overlooking critical constraints like time horizons and profit-and-loss thresholds essential for algorithmic trading. This thesis introduces a novel end-to-end language-based approach that is capable of generating profitable signals, in the Bitcoin market. It achieves this by annotating tweets based on short-term market reactions, addressing the limitations of traditional sentiment labels. Prompt engineering enhanced textual inputs with market and temporal context, incorporating features such as price changes and time references. The proposed approach was evaluated on Bitcoin data, including in-sample tweets from 2020 and out-of-sample datasets from 2015–2023. Results show that market-driven labels significantly outperform sentiment-based methods in short-term trend prediction, with the fine-tuned model achieving an F1 score of 80.3% on a dataset of 227 impactful Bitcoin events. Adding contextual information further boosted accuracy. Backtests of trading signals aggregated from model predictions demonstrated robust performance, achieving Sharpe ratios of up to 5.10 in trending markets and 3.76 in neutral markets, while reducing aggressive signals in uncertain scenarios. These findings highlight the effectiveness of market-specific labels and context-aware prompts in leveraging language models for financial forecasting and algorithmic trading strategies, offering a paradigm shift toward more precise and actionable market predictions.

Keywords: Trading Algorithms, Financial Markets, Textual Data Analysis, Sentiment Analysis



Iran University of Science and Technology
Computer Engineering Department

Improving Trading Algorithms Performance in the Cryptocurrency Market with Explainable Textual Data Analysis

Bachelor of Science Thesis in Computer Engineering

By:

Hamid Moradi Kamali

Supervisor:

Dr. Reza Entezari-Maleki

October 2024